

data

Aula 3

Nicolas de Sousa Maia

 /NicolasSMaia

Presença

- Linktree: Presente na bio do nosso instagram
- Presença ficará disponível até 1 hora antes da próxima aula
- É necessário 70% de presença para obter o certificado



Recado

- Não teremos aula nos dias: 18/04, 02/05, devido aos feriados



Presença e Github









Revisão




Classificação



Margem



Margem

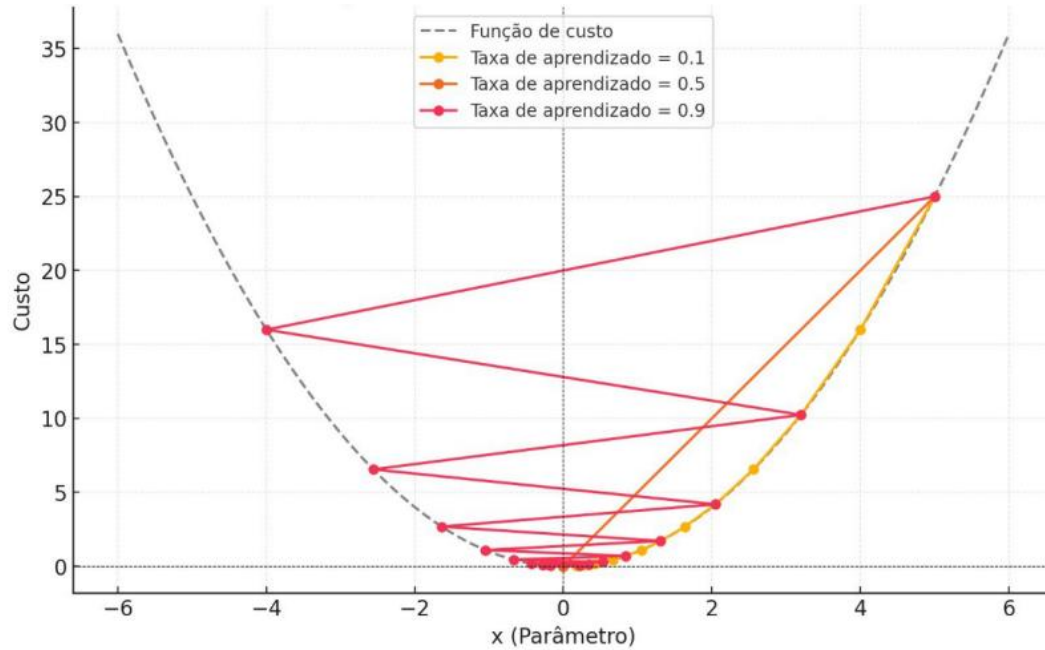


Função Objetivo

$$J(\theta, \theta_0) = \frac{1}{n} \sum_{i=1}^n \text{Loss}(y_i(\vec{\theta} \cdot \vec{x} + \theta_0)) + \frac{\lambda}{2} \|\theta\|^2$$



Gradiente





Regressão Linear



Regressão x Classificação

- Similaridade na forma
- Papel do hiperplano muda



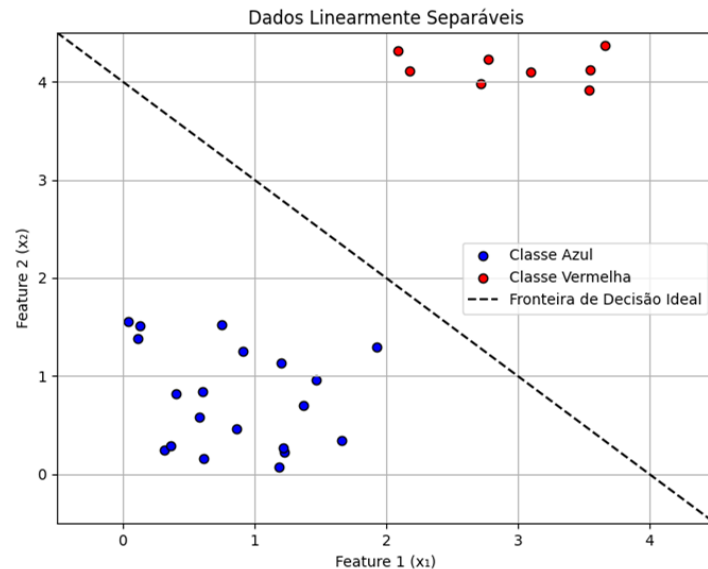

Objetivo da Regressão

- O objetivo está em prever um valor de saída para um novo valor de entrada, que pode ser 1 ou mais valores



Regressão x Classificação

- Colocando lado a lado, a diferença está no papel do hiperplano:



Regressão

Tabela 1: Dados de Tamanho e Preço de Imóveis

Casa	Tamanho (m²) (X)	Preço (R\$ mil) (Y)
1	50	300
2	70	380
3	80	420
4	90	470
5	100	530
6	120	600



Regressão

- O modelo da regressão linear segue:

$$Y = aX + b$$

- Encontramos os valores ótimos para o coeficiente angular e o coeficiente linear (chamado de intercepto)



Regressão

- Para o exemplo dado, temos:

$$\hat{Y} = 5X + 50$$

- Portanto, para um novo X , podemos prever com:


$$\hat{Y} = 5 \times 110 + 50 = 600 \text{ mil reais}$$

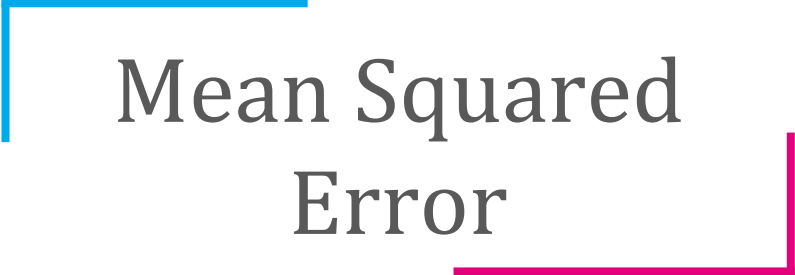
- A forma com que encontramos os parâmetros será explicada na sequência



Regressão

- Para visualização, temos o seguinte gráfico da regressão linear encontrada:





Mean Squared Error



Two L-shaped lines, one blue and one magenta, framing the text. The blue line is on the left, and the magenta line is on the right.

Lousa



Mean Squared Error (MSE)

- Uma das principais Loss

$$L(f(x_i, \theta), y_i) = \frac{(y_i - f(x_i))^2}{2} = \frac{(y_i - \theta x_i)^2}{2}$$

- Intensifica a Perda, tanto para baixo quanto para cima



Detalhe!

$$\theta = (\theta_{\textit{antigo}}, \theta_0)$$



Detalhe!

$$\theta = (\theta_{antigo}, \theta_0)$$

$$x = (x_{antigo}, 1)$$



Detalhe!

$$x \cdot \theta = x_{antigo} \cdot \theta_{antigo} + 1 * \theta_0$$





Empirical Risk



Empirical Risk

**Função de Perda da
Última Aula**

Quantificava o erro
baseado em um único
dado



Empirical Risk

Função de Perda da

Última Aula

Quantificava o erro
baseado em um único
dado

X

Empirical Risk

Quantifica o erro baseado
em todos os dados de
treinamento



Empirical Risk

- Ideia: Média Aritméticas das Perdas

$$R_n(f(x_i)) = \frac{1}{n} \sum_{i=1}^n L(f(x_i), y_i)$$



Mean Squared Error (MSE)

- Empirical Risk com MSE

$$R_n(\theta) = \frac{1}{n} \sum_{i=1}^n \frac{(y^i - \theta x^i)^2}{2}$$





Regressão e Gradiente



Relembrando o Algoritmo do SGD

1. $\theta = \text{valor aleatório}; \theta_0 = \text{valor aleatório}$
2. for t in range(T)
3. sortear i em: $\{x_0, x_1, \dots, x_n\}$
4. $\theta = \theta - \eta \nabla_{\theta}[J]$



Gradiente do MSE

- Utilizando o MSE como Loss, podemos calcular seu Gradiente

$$\nabla L(f(x_i, y_i)) = \frac{\partial L(f(x_i, y_i))}{\partial \theta} = \frac{\frac{\partial (y_i - \theta x_i)^2}{2}}{\partial \theta} = -x_i(y_i - \theta x_i)$$

- Caminharemos na Direção Contrário ao Gradiente: $+x_i(y_i - \theta x_i)$



Gradiente do MSE

- Algoritmo de Atualização de θ

1. Inicializar $\theta = 0$
2. Tomar randomicamente um $t = 1, \dots, n$
3. $\theta = \theta + \eta x^t (y^t - \theta x^t)$





Prática 1





Feature Transformation



Definição


- Transformação matemática do vetor de features
- Tem como intuito mudar o espaço em que estamos trabalhando
- Pode ser de vários tipos

$$(x_1, x_2) \xrightarrow{f} (f(x_1), f(x_2))$$


$$(x_1, x_2) \rightarrow (x_1, x_2, x_1^2, x_2^2)$$



Exemplo



$$(x_1, x_2) \rightarrow (x_1, x_2, x_1 * x_2)$$





Transformação Polinomial



Transformação Polinomial

- É a listagem de todos os monômios, formados pelos elementos do nosso vetor de features, que os graus são menores ou iguais ao grau da expansão que queremos







Transformação Polinomial

- Primeira Ordem (Linear)

$$\phi(x) = [1, x]$$

- 1: necessário para θ_0 dentro de θ







Transformação Polinomial

- Segunda Ordem (Quadrática)

$$\phi(x) = [1, x, x^2]$$

$$\phi_2(x) = [1, x_1, x_2, x_1^2, x_2^2, x_1x_2]$$







Transformação Polinomial

- Terceira Ordem (Cúbica)





$$\phi(x) = [1, x, x^2, x^3]$$

$$\phi_3(x) = [1, x_1, x_2, x_1^2, x_2^2, x_1x_2, x_1^3, x_2^3, x_1^2x_2, x_1x_2^2]$$



Alta Dimensionalidade

- Alta dimensionalidade pode causar overfitting
- Muito custoso para calcular
- Funções Kernel (próxima aula)









Regressão Polinomial



Regressão Polinomial

- Similar a regressão linear
- Vetor de características $\rightarrow \phi$
- Vetor de parâmetros terá a mesma dimensionalidade de ϕ



Regressão Polinomial

1. Inicializar $\theta = 0$
2. Tomar randomicamente um $t = 1, \dots, n$
3. $\theta = \theta + \eta \phi^t (y^t - \theta \phi^t)$





Prática 2





data@icmc.usp.br



@data.icmc



/c/DataICMC



/icmc-data



data.icmc.usp.br



obrigado por sua
presença!

